Taller 2
Taller de programación en R
Facultad de Economía, Universidad de los Andes

Fecha de entrega: 15 de marzo de 2026

Aspectos generales:

El presente taller busca que se apliquen los conceptos vistos durante las clases Magistrales de las semanas 4 a 7 del curso. Adicional a esto, con los ejercicios propuestos se busca desarrollar una mejor comprensión del uso de R, de los paquetes vistos en clase y fomentar un razonamiento lógico que lleve a los estudiantes a comprender e implementar de una buena manera los tópicos tratados.

El Taller 2 debe ser desarrollado en los grupos establecidos al respecto (sin excepciones) y entregado en la fecha fijada a través de la plataforma de Bloque Neón. No se aceptarán talleres por un medio distinto a este. Solo es necesario que una persona integrante del grupo suba el taller correspondiente. Se recomienda leer cuidadosamente todo el taller antes de empezar a desarrollarlo para que tengan un contexto general de las actividades que se solicitan.

La copia o plagio en este trabajo está totalmente prohibida e incurrir en esta práctica conlleva a una **nota de cero (0.0) en el taller**, así como a las sanciones correspondientes tenidas en cuenta en el reglamento de estudiantes de la universidad. Está permitido el uso responsable de herramientas de IA para la generación de código como Chatgpt, Copilot, Bard, entre otras. Entienda uso responsable como un apoyo para escribir su código, más no un sustituto de su tarea, motivo por el cual salidas explicitas de IAs serán penalizadas **con nota de cero (0.0) en el punto en cuestión**. La presentación del taller está en el Nivel 2 de entrega de documentos según los lineamientos de inteligencia artificial de la universidad, que puede encontrar en el siguiente enlace: https://secretariageneral.uniandes.edu.co/images/documents/lineamientos-uso-inteligencia-artificial-generativa-IAG-uniandes.pdf.

Los ejercicios del taller están hechos para ser realizados de manera autocontenida a los temas, métodos y consideraciones propias del curso. El uso de paquetes no vistos en clase está prohibido en la entrega de este taller.

La nota máxima del taller es 5,25/5,0.

Sobre plagio y uso de herramientas:

La copia o plagio en este trabajo está totalmente prohibida. Incurrir en esta práctica conlleva a una nota de cero (0) en el taller, así como a las sanciones correspondientes contempladas en el reglamento de estudiantes de la universidad.

Uso de inteligencias artificiales: Bajo los lineamientos institucionales, este taller se encuentra en **Nivel 2 de uso de inteligencia artificial**. Esto significa que está permitido consultar herramientas de IA (ChatGPT, Claude, Copilot, etc.) para resolver dudas de proceso, entender errores o aclarar conceptos. Sin embargo, está **estrictamente prohibido** copiar y pegar código generado directamente por estas herramientas en sus respuestas. El código entregado debe ser de su autoría y demostrar comprensión del problema.

Uso de herramientas y librerías: Solo se permite el uso de herramientas y librerías vistas en clase. El uso de herramientas adicionales está prohibido, a menos que el enunciado del literal lo autorice explícitamente.

Cada grupo debe entregar:

- Un script de R donde presenten el código que realizó para solucionar el mismo. El código se correrá en su totalidad en el proceso de calificación. El script debe correr de principio a fin sin errores y sin intervención manual (solo ejecutar). Asimismo, debe estar organizado por puntos y subpuntos con comentarios claros. Tenga en cuenta que no solo se evaluará el resultado, sino que se usen las herramientas trabajadas en clase.

- Un documento .pdf donde realice las interpretaciones y explicaciones necesarias para cada punto. En caso de que el punto no requiera algún desarrollo además del código, pueden explicar esto en el documento.

A. Evaluación práctica (2.5 puntos)

1. Conformación y análisis base de datos (0,75 puntos):

El presente taller buscará replicar la construcción de los principales indicadores de mercado laboral de Colombia. La base de datos base para la construcción de estos es la Gran Encuesta Integrada de Hogares (GEIH) del DANE. Los microdatos de la encuesta los encuentran en el Archivo Nacional de Datos (ANDA) del DANE. Para este ejercicio se utilizarán los datos de enero a diciembre de 2025, los cuales podrán encontrarlos y descargarlos en el siguiente enlace: https://microdatos.dane.gov.co/index.php/catalog/853.

Los microdatos deberán ordenarlos según la carpeta que se adjunta con el nombre “GEIH_2025”. Solo deberán tener en cuenta las bases en formato .csv y su nombre no debe cambiarse para garantizar que el código entregado corra solo cambiando el directorio en el que se encuentra ubicada la carpeta mencionada. Si el código no corre solo modificando dicha ruta, **la nota del taller será cero (0.0)**. Las bases de datos que deben tener en cuenta para resolver el taller son los siguientes módulos de la GEIH:

1. Características generales, seguridad social en salud y educación.CSV
   Este capítulo brinda las características generales de la población tales como sexo, edad, nivel educativo, afiliación a seguridad social, entre otras características. Esta base contiene los registros de total las personas encuestadas.

2. Fuerza de trabajo.CSV
   Este capítulo permite caracterizar a la Población en Edad de Trabajar (PET) entre población en la Fuerza de Trabajo (población ocupada o desocupada) o Fuera de la Fuerza de Trabajo (FFT). Esta base contiene los registros de la PET (15 años y más).

3. Ocupados.CSV
   Este módulo brinda la información de las características de la PET clasificada como ocupada y de sus empleos.

4. No ocupados.CSV

Este capítulo caracteriza a la PET clasificada como no ocupada, es decir, todas las personas desocupadas o la población fuera de la fuerza de trabajo.

Una vez se descarguen y ordenen las bases de datos para cada mes, deberán desarrollar los siguientes puntos:

1.1 Pegue de las bases de datos (0.5 puntos).

Deberá crear la base de datos de la GEIH 2025. Para ello, debe crear un loop que realice el merge de los datos de enero a diciembre. El loop deberá tomar las bases de cada mes y realizar el pegue teniendo en cuenta que el módulo básico para construir la información del mes es "Características generales, seguridad social en salud y educación.CSV", el cual contiene la información de todas las personas encuestadas para cada mes. Una vez se construya la base de cada mes, se integrarán para construir la base total del año.

Tenga en cuenta que en la GEIH la llave para el merge de los registros está compuesta por las variables DIRECTORIO, SECUENCIA_P y ORDEN. Consulte a qué hace referencia cada una de estas y consigne dicha información en el documento. Asimismo, describa las generalidades de la GEIH, las cuales podrá consultar en los materiales relacionados en el enlace del ANDA referenciado anteriormente y en los boletines de mercado laboral publicados por el DANE mensualmente. También, incluya una descripción de la lógica utilizada para construir el loop para el merge de las bases.

1.2 Descripción general de los datos (0.125 puntos)

Uno de los elementos clave de un analista de datos es entender las bases que está trabajando. En este punto deberá realizar una descripción básica de la base de datos de la GEIH 2025. Para tal fin, cree una tabla en la que describa el tamaño total de la muestra para cada mes y el total del año 2025. Asimismo, debe incluir el número de observaciones para cada uno de los módulos de la encuesta que deben tenerse en cuenta en este ejercicio (características generales, fuerza de trabajo, ocupados, no ocupados). Explique a qué se debe la diferencia en el número de observaciones de cada una de estas bases de datos. Para ello, podría consultar el Formulario y Manual de recolección y conceptos básicos de la GEIH.

1.3 Selección de las variables relevantes para el análisis (0.125 puntos)

Tal como podrá observar en su base de datos, la GEIH cuenta con una gran cantidad de variables. La relación y categoría de estas podrá encontrarla en el formulario, diccionario y manual de recolección de la encuesta. En este punto, analizará las variables que se deberán tener en cuenta para el análisis que se desarrollará en el taller.

Por favor, en la base de datos final filtre las variables que se mencionarán a continuación según cada módulo de la GEIH:

a) Características generales, seguridad social en salud y educación: DIRECTORIO, SECUENCIA_P, ORDEN, PERIODO, MES, P3271, P3042, P6090, P6040, P6160, DPTO, FEX_C18, PT.
b) Fuerza de trabajo: PET, FT, FFT, P6240.
c) Ocupados: OCI, RAMA2D_R4, P6430, INGLABO.
d) No ocupados: DSI

La base final en este punto sólo debe tener las variables señaladas y una variable para el año que deberá construir a partir de la variable PERIODO. Asimismo, en el código deberá crear las etiquetas necesarias para rotular cada variable y así facilitar el desarrollo de los puntos siguientes. Por ejemplo, la variable P3271 se debe etiquetar como "Sexo" con categorías "1 = Hombre" y "2 = Mujer". En el documento, incluya una breve descripción de cada una de las variables seleccionadas.

2. Construcción de los principales indicadores de mercado laboral (0,75 puntos):

En este punto se replicarán los principales indicadores de mercado laboral de Colombia. Por tanto, **los datos mensuales que obtenga deberán coincidir con los publicados por el DANE en su anexo estadístico de empleo**, el cual podrá consultar en el siguiente enlace: https://www.dane.gov.co/index.php/estadisticas-por-tema/mercado-laboral/empleo-y-desempleo.

2.1 Tasas y poblaciones (0,2 puntos)

Construya una tabla como la que se muestra abajo con los principales indicadores de mercado laboral para el total nacional para los meses comprendidos entre enero y diciembre de 2025. Para ello, construya un dataframe y posteriormente expórtelo como una tabla de Excel que deberá incluir en el documento. La estructura de la tabla debe ser la siguiente:

Tasas (%) y poblaciones	Enero 2025	…	Diciembre 2025
Tasa global de participación (TGP)			
Tasa de ocupación (TO)			
Tasa de desempleo (TD)			
Población total			
Población en edad de trabajar (PET)			
Fuerza de trabajo			
Población ocupada			
Población desocupada			

Las definiciones de las tasas y poblaciones podrá encontrarlas en el boletín técnico en el enlace señalado en el encabezado del segundo punto o en el Manual de recolección de la GEIH en el enlace del ANDA. En este punto y en adelante, tenga en cuenta que para obtener los datos poblacionales deberá expandir los datos muestrales con la variable FEX_C18.[1]

2.2 Análisis de las tasas de mercado laboral (0,175 puntos)

Con base en el dataframe construido en el punto anterior, cree un gráfico de serie de tiempo en el que se muestre el comportamiento de la TGP, TO y TD entre enero-diciembre 2025 para el total nacional. Tenga en cuenta que la TD tiene una escala menor a las otras dos tasas, por lo cual, esta deberá mostrarla en un segundo eje para ver con claridad el comportamiento de todas las tasas.

Por favor, incluya título, colores y marcadores diferenciados para cada tasa, labels, leyenda, título de los ejes y demás elementos que permitan obtener una gráfica autocontenida. Explique e interprete en el documento la lectura de los datos observados en la gráfica.

[1] Esto quiere decir que, para obtener información agregada a nivel nacional y no muestral, deberá multiplicar los valores de las columnas pertinentes por el factor de expansión.

2.3 Población ocupada según ramas de actividad (0,2 puntos)

Cree un gráfico de barras horizontales del número de personas ocupadas según ramas de actividad económica para el mes de abril 2025 para el total agregado de las 13 ciudades y áreas metropolitanas que agrupa la encuesta[2]. El gráfico debe mostrar las ramas de actividad ordenadas de mayor a menor población.

Para ello, tome la base de GEIH 2025, filtre para el mes de abril, use las variables RAMA2D_R4 y OCI, luego realice la construcción de la variable de rama de actividad a un dígito usando la clasificación a dos dígitos (variable RAMA2D_R4) según se define a continuación:

i. Agricultura, ganadería, caza, silvicultura y pesca: '01','02','03'.
ii. Explotación de minas y canteras: '05','06','07','08','09'.
iii. Industrias manufactureras: '10','11','12','13','14','15','16','17','18','19','20','21','22','23','24','25', '26','27','28','29','30','31','32','33'
iv. Suministro de electricidad, gas, agua y gestión de desechos: '35','36','37','38','39'.
v. Construcción: '41','42','43'.
vi. Comercio y reparación de vehículos: '45','46','47'.
vii. Alojamiento y servicios de comida: '55','56'.
viii. Transporte y almacenamiento: '49','50','51','52','53'.
ix. Información y comunicaciones: '58','59','60','61','62','63'.
x. Actividades financieras y de seguros: '64','65','66'.
xi. Actividades inmobiliarias: '68'.
xii. Actividades profesionales, científicas, técnicas y de servicios administrativos: '69','70','71', '72','73','74', '75','77','78','79','80','81','82'.
xiii. Administración pública y defensa, educación y atención de la salud humana: '84','85','86', '87','88'.
xiv. Actividades artísticas, entretenimiento, recreación y otras actividades de servicios: '90','91', '92','93','94','95','96','97','98','99'.

Después, cree un nuevo dataframe con el total expandido (aplicando el factor de expansión) del número de personas ocupadas por rama de actividad. Con esta información puede crear el gráfico que deberá tener título, leyenda, labels, etiquetas de los datos, título de los ejes y demás elementos que considere necesarios para que sea autocontenido. Exporte el gráfico en formato png en la carpeta “outputs”, inclúyalo en el documento y explique lo que encuentra en este.

2.4 Población ocupada según posición ocupacional (0,175 puntos)

Cree un gráfico de torta (pie) con la distribución de personas ocupadas según posición ocupacional para el mes de diciembre 2025 para el total nacional. Para crear el gráfico ordene las posiciones ocupacionales alfabéticamente.

Para crear este gráfico, filtre la base final solamente para el mes de febrero 2025, use las variables P6430 y OCI, cree un nuevo dataframe con el total expandido del número de personas ocupadas por posición ocupacional. A partir de esto, debe crear una variable con la proporción de personas ocupadas por cada posición ocupacional y ordenarlas alfabéticamente. El gráfico deberá tener título, leyenda, labels, etiquetas de los datos en porcentaje, título de los ejes y demás elementos que

[2] Las 13 ciudades y áreas metropolitanas definidas en la GEIH son: Bogotá D.C., Medellín A.M., Cali A.M., Barranquilla A.M., Bucaramanga A.M., Manizales A.M., Pereira A.M., Cúcuta A.M., Pasto, Ibagué, Montería, Cartagena y Villavicencio.

considere necesarios para que sea autocontenido. Exporte el gráfico en formato png en la carpeta "outputs", inclúyalo en el documento y explique lo que encuentra en este.

3. Análisis socioeconómico de la población colombiana (1,0 punto) – Ejercicio libre:

La GEIH ofrece una gran cantidad de datos más allá de la construcción de los indicadores de mercado laboral. Dada su cobertura nacional y recolección continua, la convierte en una de las principales fuentes de información socioeconómica en Colombia. Con esta, también puede construir indicadores desagregados por edad, nivel educativo, analfabetismo, ingreso laboral, afiliación a seguridad social, entre otros, para el total de la población nacional o por departamento.

En este punto, explore la encuesta y seleccione las variables que considere interesantes para el análisis más allá de las abordadas en los puntos anteriores a nivel de mercado laboral. Cree cuatro gráficas y realice un análisis socioeconómico de la población colombiana para el año 2025. La elección temporal es libre (valores anuales, semestrales, trimestrales, mensuales), tengan cuidado al expandir las poblaciones con la variable FEX_C18.

Se tendrá en cuenta la calidad del análisis, la creatividad de las gráficas y que las mismas estén autocontenidas. No olvide exportarlas en formato png para adjuntarlas en el documento. Algunos lineamientos básicos:

a. Utilizar 4 tipos de gráficos distintos para este análisis.
b. Usar 4 conjuntos distintos de variables para el análisis de cada gráfico.
c. Por lo menos uno de los gráficos debe estar desagregado en unidad geográfica menor al nivel nacional. Por ejemplo, región, departamento, ciudad.
d. Por lo menos uno de los gráficos debe utilizar alguna variable porcentual. Pueden utilizar distribuciones apiladas (stacked bars)
e. Deben presentar en párrafos de máximo 150 palabras los resultados asociados a cada uno de los gráficos. ¿Qué encuentran? ¿Por qué es importante a nivel socioeconómico?
f. El grupo que envíe los 4 gráficos más interesantes recibirá un **bono de 0.25 sobre la nota del taller**. Los gráficos y reseñas relevantes serán publicados dentro de Bloque Neón.

B. Evaluación oral (2.5 puntos)

La evaluación oral se llevará a cabo en sesiones de plenaria con una duración aproximada de 20 a 25 minutos por grupo. Este espacio tiene como objetivo evaluar la capacidad de cada grupo para comunicar, argumentar y defender los resultados obtenidos en el desarrollo del taller. Se espera que los estudiantes demuestren dominio sobre los datos trabajados, claridad en la interpretación de los indicadores construidos y capacidad de síntesis al presentar sus hallazgos. La nota de esta sección es grupal y aplica únicamente para los integrantes del grupo que asistan a la sesión de plenaria correspondiente. Aquellos integrantes que no asistan obtendrán una nota automática de 0.0 en esta sección, salvo que presenten una excusa válida según la normativa de la universidad.

En las sesiones de 20 a 25 minutos, el equipo pedagógico formulará preguntas orientadas a evaluar la comprensión individual y colectiva de los procedimientos realizados, la narrativa detrás de los resultados, las observaciones extraídas de los datos y el manejo de errores o dificultades encontrados durante la ejecución del código. Las preguntas estarán orientadas tanto en términos técnicos propios del curso como en la capacidad de oratoria y comunicación efectiva de cada

integrante. Se publicará oportunamente una rúbrica detallada con los criterios de evaluación específicos para esta sección.

Consideren este ejercicio como una oportunidad para enfrentarse a un escenario similar al de una entrevista técnica para cargos de análisis de datos o consultoría. En estos contextos profesionales, no basta con saber ejecutar código: es fundamental poder explicar con claridad qué se hizo, por qué se hizo y qué significan los resultados obtenidos. Del mismo modo, al ser este un curso de programación en R, se espera que cada integrante demuestre dominio sobre las herramientas, funciones y lógica de programación utilizadas en el desarrollo del taller. Las preguntas del equipo pedagógico podrán abordar tanto la interpretación de resultados como la justificación técnica de las decisiones tomadas en el código. Por ello, se recomienda que el desarrollo del taller se realice de manera colaborativa dentro del grupo, de modo que todos los integrantes estén en capacidad de responder con solidez tanto a preguntas sobre los hallazgos como sobre la implementación técnica en R.